Защищено:	Демонстрация: Гапанюк Ю.Е.		
Гапанюк Ю.Е.	""	2022 г.	
"2022 г.			
Отчет по лабораторной ра Технологии машинн ГУИМП	ого обучения	рсу	
Тема работы: " Линейные модел	пи, SVM и дерен	вья решений. "	
11 (количество лис <u>Вариант №</u> 1			
ИСПОЛНИТЕЛЬ:			
студент группы ИУ5-63Б			
Наказной Н.А.	(подпись ""	2022 г.	
Москва, МГТ	y - 2022		

Цель лабораторной работы:

изучение линейных моделей, SVM и деревьев решений.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
 - о одну из линейных моделей (линейную или полиномиальную регрессию при решении задачи регрессии, логистическую регрессию при решении задачи классификации);
 - o SVM;
 - о дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.
- 6. Постройте график, показывающий важность признаков в дереве решений.
- 7. Визуализируйте дерево решений или выведите правила дерева решений в текстовом виде.

Ход выполнения работы

В качестве набора данных используется dataset - Результаты студентов на экзаменах (Оценки, полученные учащимися по различным предметам). Датасет доступен по адресу:

https://www.kaggle.com/datasets/spscientist/students-performance-in-exams

Из набора данных будет рассматриваться только файл « StudentsPerformance.csv»

Лабораторная работа №4

```
import numpy as np
In [1]:
          import pandas as pd
          from typing import Dict, Tuple
          import seaborn as sns
          import matplotlib.pyplot as plt
          %matplotlib inline
          from sklearn.impute import SimpleImputer
          import warnings
          from sklearn.pipeline import Pipeline
          from sklearn.preprocessing import PolynomialFeatures
          from sklearn.metrics import confusion matrix, precision score, recall score, f1 scor
          from sklearn.linear model import LinearRegression
          warnings.simplefilter("ignore")
          # чтение обучающей выборки
In [2]:
          data = pd.read csv('StudentsPerformance.csv')
          data.head()
                                                                      test
Out[2]:
                                  parental level of
                                                                           math
                                                                                 reading writing
                                                       lunch
                                                               preparation
            gender race/ethnicity
                                       education
                                                                           scor
                                                                                   score
                                                                                            scor
                                                                   course
                                                                                            е
         0
            female
                         group B bachelor's degree
                                                     standard
                                                                     none
                                                                              72
                                                                                      72
                                                                                              74
         1
            female
                         group C
                                     some college
                                                     standard
                                                                 completed
                                                                              69
                                                                                      90
                                                                                              88
         2
            female
                         group B
                                   master's degree
                                                     standard
                                                                              90
                                                                                      95
                                                                                              93
                                                                     none
                                       associate's
         3
              male
                         group A
                                                  free/reduced
                                                                     none
                                                                              47
                                                                                      57
                                                                                              44
                                          degree
                                                                                              75
         4
                                                                              76
                                                                                      78
              male
                                     some college
                                                     standard
                         group C
                                                                     none
          from sklearn.model selection import train test split
In [3]:
          from sklearn.preprocessing import LabelEncoder
         le = LabelEncoder()
In [4]:
              # "gender" - пол
          le.fit(data.gender.drop_duplicates())
          data.gender = le.transform(data.gender)
              # "race/ethnicity" - paca
          le.fit(data["race/ethnicity"].drop_duplicates())
          data["race/ethnicity"] = le.transform(data["race/ethnicity"])
              # "Lunch" - обед
          le.fit(data.lunch.drop_duplicates())
          data.lunch = le.transform(data.lunch)
              # "parental level of education" - образование родителей
          le.fit(data["parental level of education"].drop_duplicates())
          data["parental level of education"] = le.transform(data["parental level of education
              # "test preparation course" - подготовительный курс
          le.fit(data["test preparation course"].drop_duplicates())
          data["test preparation course"] = le.transform(data["test preparation course"])
In [5]:
          #Построим корреляционную матрицу
          fig, ax = plt.subplots(figsize=(15,7))
          sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
Out[5]: <AxesSubplot:>
```



Предскажем значения поля Writing score по Math score и Reading score, так как значение корреляции ближе всего к 1.

```
In [6]: X = data[["math score", "reading score"]]
Y = data["writing score"]
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
```

Входные данные:

	math	score	reading	score
0		72		72
1		69		90
2		90		95
3		47		57
4		76		78

Выходные данные:

Name: writing score, dtype: int64

Входные параметры обучающей выборки:

	math	score	reading	score
785		32		51
873		90		90
65		67		64
902		34		48
317		83		72

Входные параметры тестовой выборки:

math score reading score

```
    993
    62
    72

    859
    87
    73

    298
    40
    46

    553
    77
    62

    672
    69
    78
```

Выходные параметры обучающей выборки:

```
785 44
873 82
65 61
902 41
317 78
Name: writing score, dtype: int64
```

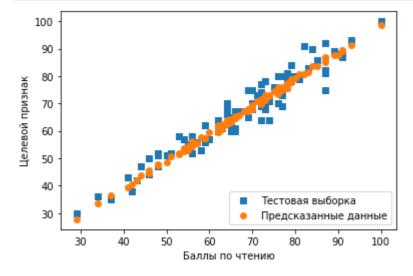
Выходные параметры тестовой выборки:

```
993 74
859 72
298 50
553 64
672 76
Name: writing score, dtype: int64
```

Построение линейной регрессии

Возьмем тот параметр, чья корреляция ближе всего к единице, т.е. Reading score

```
In [10]: plt.scatter(X_test["reading score"], Y_test, marker = 's', label = 'Тестовая выбо
plt.scatter(X_test["reading score"], lr_y_pred, marker = 'o', label = 'Предсказанные
plt.legend (loc = 'lower right')
plt.xlabel ('Баллы по чтению')
plt.ylabel ('Целевой признак')
plt.show()
```



SVM

In [11]: from sklearn.svm import SVC , LinearSVC

```
from matplotlib import pyplot as plt
In [12]:
          svc = SVC(kernel='linear')
          svc.fit(X_train,Y_train)
         SVC(kernel='linear')
Out[12]:
          pred_y = svc.predict(X_test)
In [13]:
In [14]:
          plt.scatter(X test["reading score"], Y test,
                                                            marker = 's', label = 'Тестовая выбо
          plt.scatter(X_test["reading score"], pred_y, marker = 'o', label = 'Предсказанные да
          plt.legend (loc = 'lower right')
          plt.xlabel ('Баллы по чтению')
          plt.ylabel ('Целевой признак')
          plt.show()
            100
             90
             80
          Целевой признак
             70
             60
             50
             40
             30
                                             Тестовая выборка
                                             Предсказанные данные
             20
                  30
                        40
                              50
                                           70
                                                             100
                                     60
                                 Баллы по чтению
         Tree
In [15]:
          from sklearn.tree import DecisionTreeClassifier, DecisionTreeRegressor, export graph
          from sklearn.tree import export_graphviz
          from sklearn import tree
          import re
In [16]:
          # Обучим дерево на всех признаках iris
          clf = tree.DecisionTreeClassifier()
          clf = clf.fit(X_test, Y_test)
          from IPython.core.display import HTML
In [17]:
          from sklearn.tree.export import export_text
          tree_rules = export_text(clf, feature_names=list(X.columns))
          HTML('' + tree_rules + '')
          --- reading score <= 61.00
Out[17]:
               --- math score <= 64.50
                  |--- math score <= 53.00
                       --- reading score <= 56.50
                            --- math score <= 46.50
                                |--- reading score <= 31.50
                                    |--- class: 30
                                --- reading score > 31.50
                                    |--- math score <= 36.00
                                        |--- class: 43
                                     --- math score > 36.00
```

from sklearn.datasets.samples_generator import make_blobs

```
|--- reading score <= 38.00
                               |--- class: 36
                            --- reading score > 38.00
                               |--- reading score <= 42.50
                                   |--- class: 38
                                --- reading score > 42.50
                                   |--- math score <= 41.00
                                       |--- class: 50
                                   |--- math score > 41.00
                                       |--- math score <= 43.00
                                          |--- class: 54
                                       |--- math score > 43.00
                                       | |--- truncated branch of depth 2
                    math score > 46.50
                   |--- reading score <= 45.00
                       |--- class: 35
                    --- reading score > 45.00
                       |--- reading score <= 53.50
                           |--- class: 58
                       |--- reading score > 53.50
                           |--- math score <= 47.50
                              |--- class: 53
                           |--- math score > 47.50
                           1
                               |--- class: 58
              -- reading score > 56.50
               |--- reading score <= 58.00
                   |--- class: 56
               |--- reading score > 58.00
                   |--- class: 56
          -- math score > 53.00
           |--- reading score <= 49.50
               |--- math score <= 58.50
                    |--- math score <= 54.50
                      |--- class: 52
                   |--- math score > 54.50
                       |--- reading score <= 47.00
                          |--- class: 44
                       |--- reading score > 47.00
                       | |--- class: 51
               |--- math score > 58.50
                  |--- class: 47
           |--- reading score > 49.50
               |--- math score <= 63.00
                   --- reading score <= 53.00
                     |--- class: 52
                   |--- reading score > 53.00
                   | |--- class: 55
               |--- math score > 63.00
                   |--- class: 52
    --- math score > 64.50
       |--- reading score <= 57.00
           |--- class: 57
        --- reading score > 57.00
           |--- reading score <= 59.00
              |--- class: 53
           |--- reading score > 59.00
              |--- class: 57
|--- reading score > 61.00
```

```
|--- reading score <= 68.50
    --- reading score <= 66.50
        |--- math score <= 69.50
            |--- math score <= 60.00
                |--- reading score <= 62.50
                   |--- math score <= 45.50
                       |--- class: 61
                    --- math score > 45.50
                        |--- math score <= 53.50
                          |--- class: 60
                        |--- math score > 53.50
                        | |--- class: 64
                |--- reading score > 62.50
                   |--- reading score <= 63.50
                       |--- class: 62
                    --- reading score > 63.50
                        |--- math score <= 55.00
                            |--- reading score <= 64.50
                           | |--- class: 68
                           |--- reading score > 64.50
                            | |--- class: 65
                        |--- math score > 55.00
                            |--- class: 63
                math score > 60.00
                |--- reading score <= 62.50
                   |--- class: 60
                --- reading score > 62.50
                    |--- reading score <= 65.50
                       |--- class: 61
                    |--- reading score > 65.50
                        |--- math score <= 62.00
                           |--- class: 61
                        |--- math score > 62.00
                        | |--- class: 67
          -- math score > 69.50
            |--- reading score <= 64.50
                |--- reading score <= 63.00
                   |--- class: 64
               |--- reading score > 63.00
                   |--- math score <= 73.00
                      |--- class: 70
                   |--- math score > 73.00
                   | |--- class: 66
            --- reading score > 64.50
               |--- class: 60
    |--- reading score > 66.50
       |--- class: 67
--- reading score > 68.50
    --- reading score <= 70.50
        --- reading score <= 69.50
            |--- math score <= 63.00
            | |--- class: 65
            |--- math score > 63.00
              |--- class: 75
       |--- reading score > 69.50
            |--- math score <= 71.50
                |--- math score <= 59.00
                   |--- math score <= 55.50
```

```
|--- class: 70
               |--- math score > 55.50
                   |--- class: 68
           |--- math score > 59.00
              |--- class: 70
        --- math score > 71.50
           |--- class: 75
--- reading score > 70.50
   |--- reading score <= 81.50
        --- reading score <= 77.50
           |--- math score <= 76.50
               |--- math score <= 74.50
                   |--- reading score <= 75.00
                       |--- math score <= 57.50
                           |--- class: 64
                        --- math score > 57.50
                           |--- math score <= 62.50
                               |--- class: 74
                           |--- math score > 62.50
                               |--- reading score <= 72.50
                                  |--- class: 77
                               |--- reading score > 72.50
                                   |--- truncated branch of depth 3
                               |--- reading score > 75.00
                       |--- math score <= 54.50
                           |--- class: 70
                       |--- math score > 54.50
                           |--- reading score <= 76.50
                              |--- class: 80
                           |--- reading score > 76.50
                               |--- math score <= 61.00
                                   |--- class: 80
                               |--- math score > 61.00
                               | |--- truncated branch of depth 2
                --- math score >
                                 74.50
                   |--- class: 68
           |--- math score > 76.50
               |--- reading score <= 74.00
                   |--- reading score <= 72.50
                       |--- math score <= 79.50
                          |--- class: 69
                       |--- math score > 79.50
                           |--- class: 73
                   |--- reading score > 72.50
                       |--- class: 72
               |--- reading score > 74.00
                   |--- reading score <= 75.50
                       |--- class: 76
                   |--- reading score > 75.50
                      |--- reading score <= 76.50
                          |--- class: 74
                       |--- reading score > 76.50
                       |--- class: 73
         -- reading score > 77.50
           |--- math score <= 73.50
               |--- math score <= 58.00
                   |--- class: 79
               |--- math score > 58.00
```

```
|--- reading score <= 78.50
                  |--- class: 76
                --- reading score > 78.50
                   |--- class: 79
       |--- math score > 73.50
           |--- math score <= 87.50
               |--- reading score <= 78.50
                   |--- class: 81
               |--- reading score > 78.50
                  |--- reading score <= 79.50
                     |--- math score <= 76.50
                       | |--- class: 80
                       |--- math score > 76.50
                       | |--- class: 78
                   --- reading score > 79.50
                   | |--- class: 80
           |--- math score > 87.50
               |--- math score <= 91.50
                 |--- class: 79
               |--- math score > 91.50
                   |--- class: 84
--- reading score > 81.50
   |--- reading score <= 89.50
       |--- math score <= 74.00
           |--- reading score <= 85.00
             |--- class: 83
           |--- reading score > 85.00
              |--- class: 82
       |--- math score > 74.00
           |--- math score <= 78.00
               |--- class: 91
           |--- math score > 78.00
               |--- math score <= 84.50
                  |--- reading score <= 87.00
                   | |--- class: 86
                   |--- reading score > 87.00
                   | |--- class: 89
               |--- math score > 84.50
                  |--- math score <= 91.50
                       |--- class: 75
                   |--- math score > 91.50
                       |--- reading score <= 85.50
                          |--- class: 90
                       --- reading score > 85.50
                       | |--- math score <= 96.50
                           | |--- class: 92
                           |--- math score > 96.50
                           | |--- class: 81
     -- reading score > 89.50
       |--- math score <= 79.00
           |--- class: 88
       |--- math score > 79.00
           |--- math score <= 81.50
              |--- class: 87
            --- math score > 81.50
               |--- math score <= 87.00
                 |--- class: 93
```

```
In [18]: pred_y = clf.predict(X_test)
   plt.scatter(X_test["reading score"], Y_test, marker = 's', label = 'Тестовая выбо
   plt.scatter(X_test["reading score"], pred_y, marker = 'o', label = 'Предсказанные да
   plt.legend (loc = 'lower right')
   plt.xlabel ('Баллы по чтению')
   plt.ylabel ('Целевой признак')
   plt.show()
```

